法律声明

- 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。

关注 **小象学院**

第二讲

pandas

$$y_i t = \beta' x_{it} + \mu_i + \epsilon_{it}$$

数据分析库Pandas

--Robin

目录

- 基本数据对象及操作
- 数据清洗
- 数据合并及分组
- 数据可视化Seaborn
- 实战案例2：客户消费数据分析

目录

- 基本数据对象及操作
- 数据清洗
- 数据合并及分组
- 数据可视化Seaborn
- 实战案例2：客户消费数据分析

基本数据对象及操作

Pandas

- 2008年由Wes McKinney创建
- 一个强大的分析结构化数据的工具集
- 基础是NumPy，提供了高性能矩阵的运算

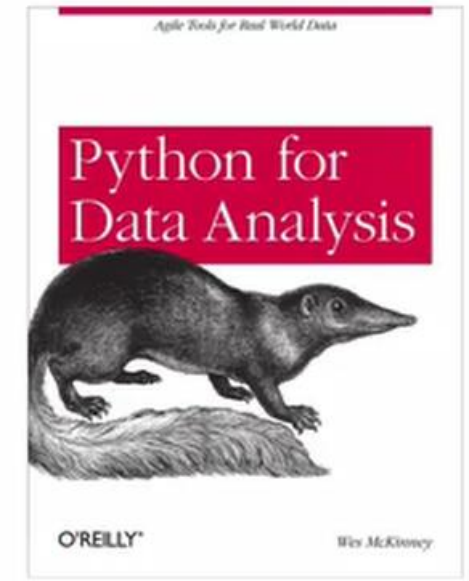

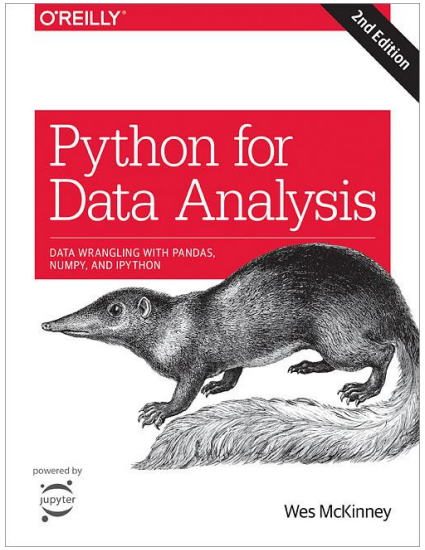

基本数据对象及操作

Series

- 类似一维数组的对象
- 通过list构建Series
  - ser_obj = pd.Series(range(10))
- 由数据和索引组成
  - 索引在左，数据在右
  - 索引是自动创建的
- 获取数据和索引
  - ser_obj.index, ser_obj.values
- 预览数据
  - ser_obj.head(n)

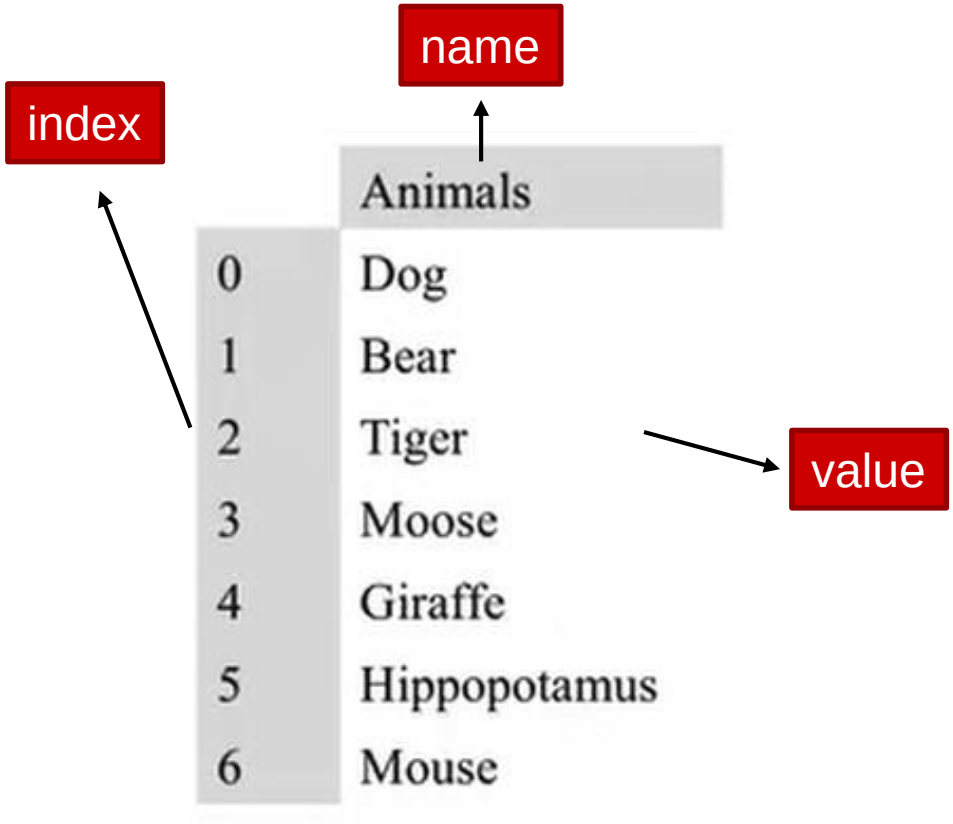

lect02_eg01.ipynb

基本数据对象及操作

Series (续)

- 通过索引名(字符串)获取数据，ser_obj['idx_name'], 或 ser_obj.loc['idx_name']
  - 如果索引名不存在，则新建一项记录
- 通过in判断数据是否存在，Series也可看作定长、有序的字典
- 通过索引位置(整型数据)获取数据，ser_obj.iloc[idx]
- 索引与数据的对应关系仍保持在数组运算的结果中
- 通过dict构建Series
- name属性
  - ser_obj.name, ser_obj.index.name
- Pandas会根据数据类型自动处理缺失数据
  - 如object -> None, float -> NaN
- 仍然可以使用NumPy中的向量化操作

```
lect02_eg01.ipynb
```

基本数据对象及操作

DataFrame

- 类似多维数组/表格数据 (如，excel, R中的data.frame)
- 每列数据可以是不同的类型
- 索引包括行索引(index)和列索引(label)

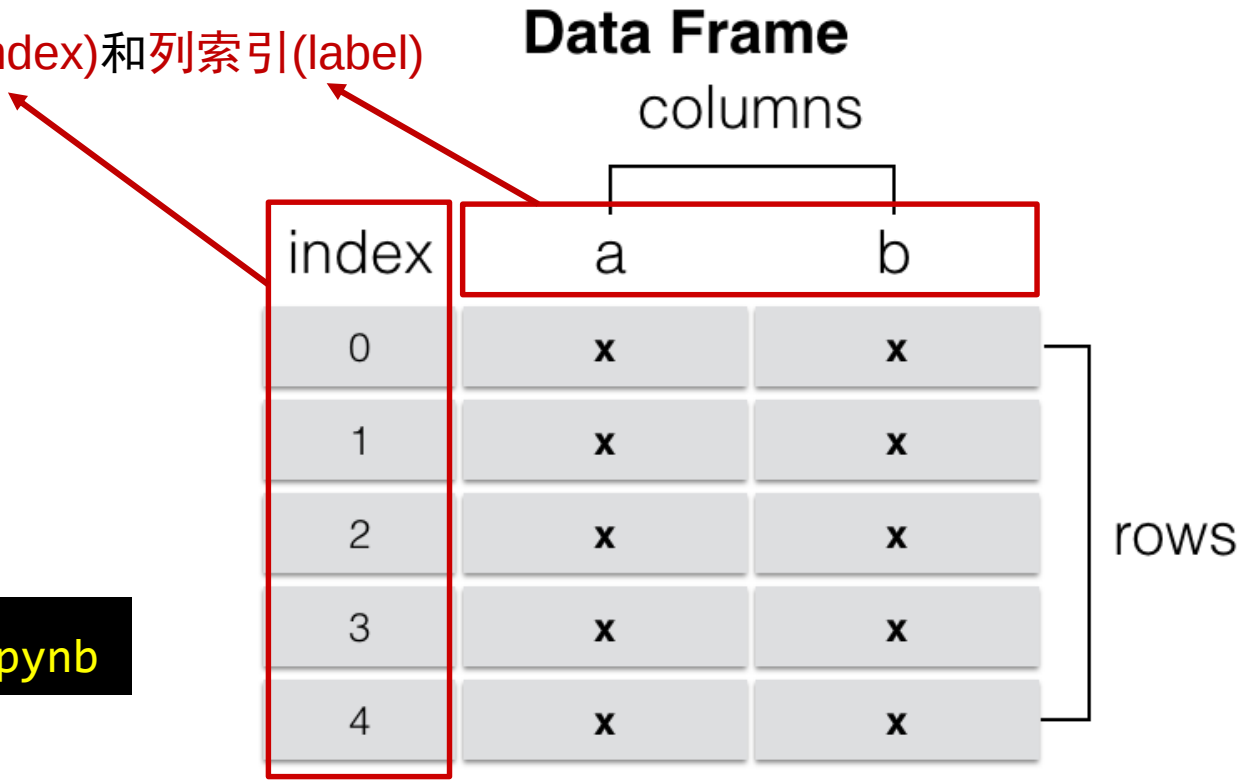


```
lect02_eg01.ipynb
```

基本数据对象及操作

DataFrame

- 通过ndarray构建DataFrame
- 通过dict构建DataFrame
- 通过列索引获取列数据（Series类型 ）
  - df_obj[label] 或 df_obj.label
- 增加列数据，类似dict添加key-value
  - df_obj[new_label] = data
- 删除列
  - del df_obj[col_idx]

```
lect02_eg01.ipynb
```

基本数据对象及操作

索引操作

- Series索引
  - 行索引，ser_obj[‘label’], ser_obj[pos]
  - 切片索引，ser_obj[2:4], ser_obj[‘label1’: ’label3’]
    - 注意，按索引名切片操作时，是包含终止索引的。
  - 不连续索引，ser_obj[[‘label1’, ’label2’, ‘label3’]]

    ser_obj[[pos1, pos2, pos3]]
  - 布尔索引

```
lect02_eg01.ipynb
```

基本数据对象及操作

索引操作 (续)

- DataFrame索引

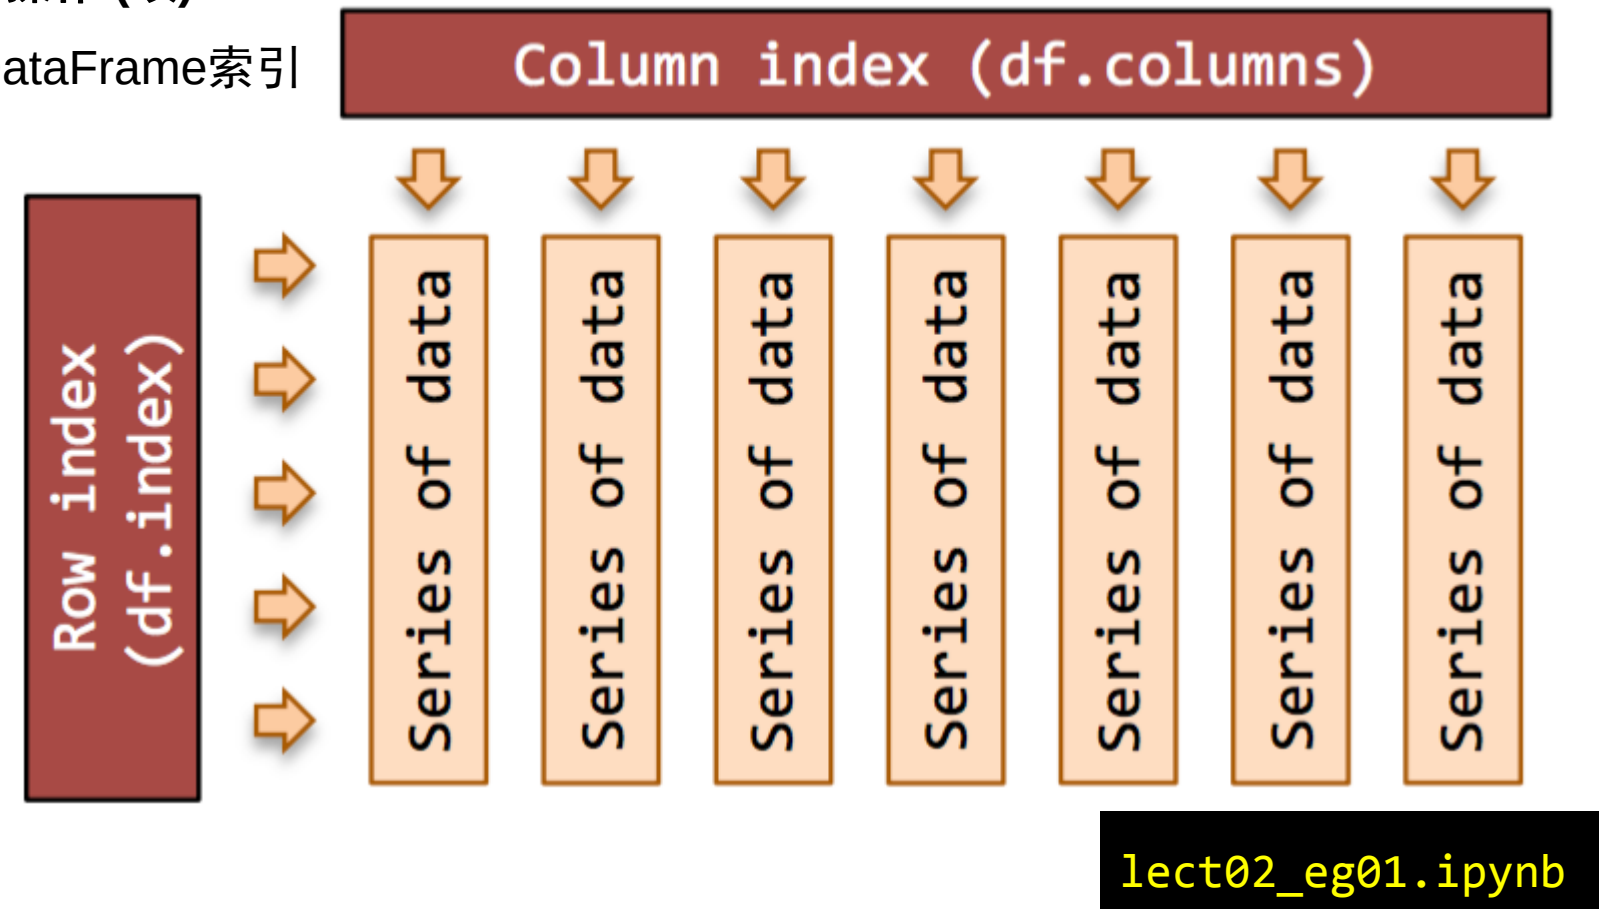

lect02_eg01.ipynb

基本数据对象及操作

索引操作 (续)

- DataFrame索引
  - 列索引：df_obj[‘label’]
  - 不连续索引：df_obj[[‘label1’, ‘label2’]]
- 注意从DataFrame中取出的数据进行操作后，会对原始数据产生影响。为了保证不对原始数据产生影响，应该使用copy()产生一个副本。在副本上进行操作。
- 数据读取
  - pd.read_csv()
  - index_col: 指定索引列
  - usecols：指定需要读取的列

lect02_eg01.ipynb

基本数据对象及操作

索引操作总结

- Pandas的索引可归纳为3种
- .loc，标签索引
- .iloc，位置索引
- loc与iloc主要用于行索引
- .ix，标签与位置混合索引
  - 先按标签索引尝试操作，然后再按位置索引尝试操作
- 注意
  - DataFrame索引时可将其看作ndarray操作
  - 标签的切片索引是包含末尾位置的

```
lect02_eg01.ipynb
```

基本数据对象及操作

索引对象Index

- Series和DataFrame中的索引都是Index对象
- 不可变(immutable)
  - 保证了数据的安全
- 常见的Index种类
  - Index
  - Int64Index
  - MultiIndex，“层级”索引
  - DatetimeIndex，时间戳类型
- 重置索引 reset_index()，将索引重新赋值为0-1
- 重命名列名：df.rename(columns={old_col: new_col}, inplace=True)

基本数据对象及操作

轴的方向

- axis=0，表示纵向计算
- axis=1，表示横向计算

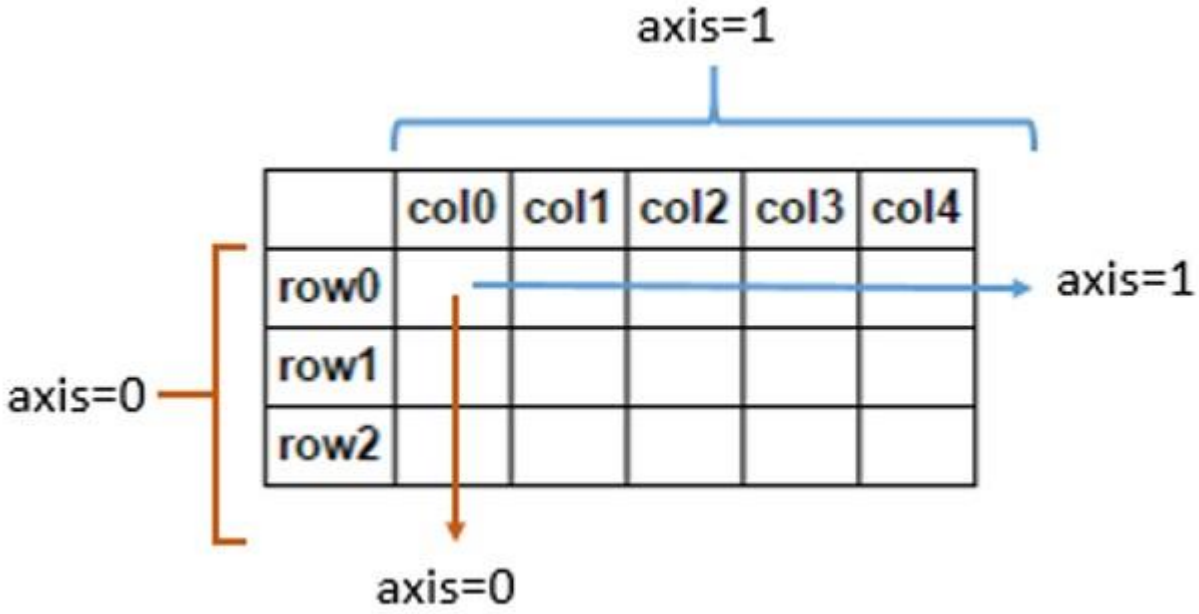

基本数据对象及操作

Boolean mask（布尔值遮罩 纯字面翻译 ☺）

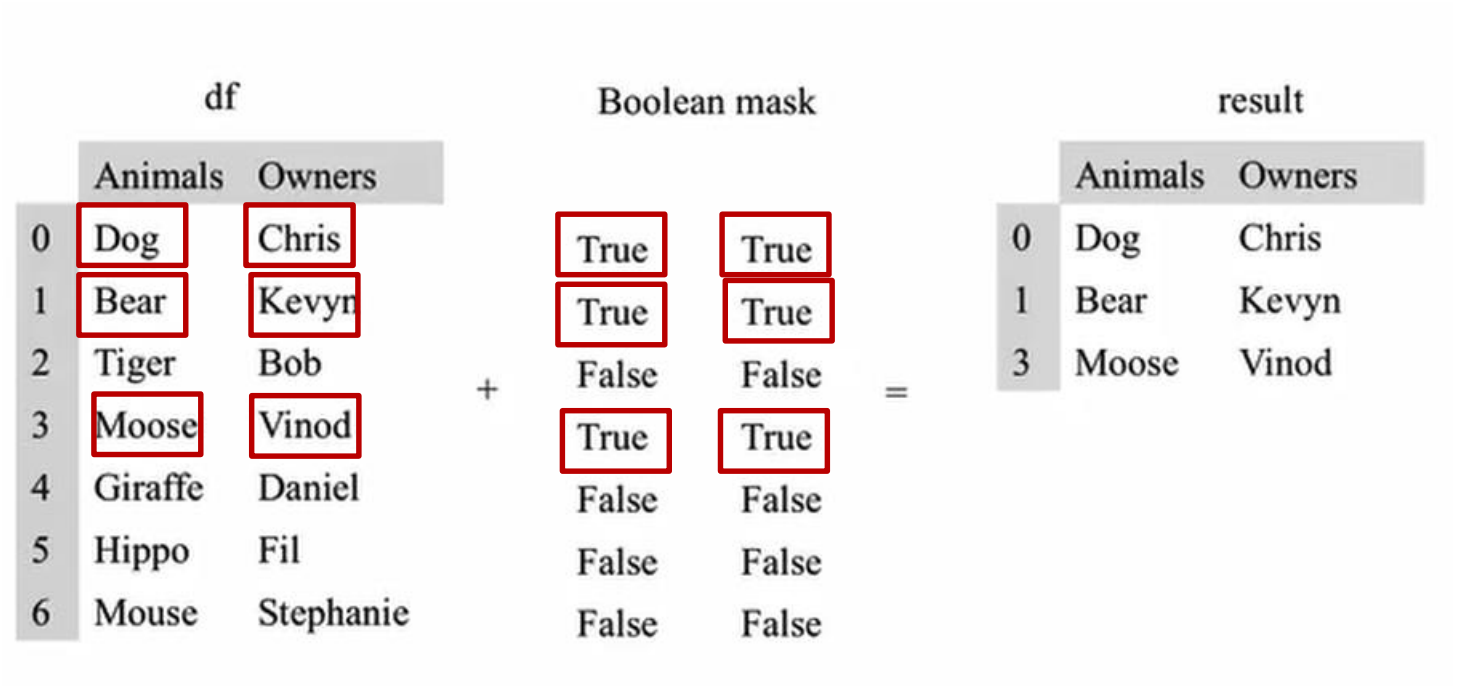

lect02_eg01.ipynb

基本数据对象及操作

层级索引（hierarchical indexing）

- MultiIndex对象
- set_index([‘a’,’b’], inplace=True)，注意a, b的先后顺序
- 选取子集
  - 外层选取 ser_obj.loc[‘outer_index’]
  - 内层选取 ser_obj.loc[‘out_index’, ‘inner_index’]
- 常用于分组操作、透视表的生成等
- 交换分层顺序
  - swaplevel()
- 排序分层
  - sort_index(level=)

lect02_eg01.ipynb

基本数据对象及操作

层级索引（续）

		0	1	2	3
bar	one	-1.133800	0.548640	1.109034	0.643708
	two	-0.792654	0.518681	-0.611958	0.913413
baz	one	0.775624	-2.520829	-0.472691	-0.557803
	two	0.190005	0.435193	1.635680	1.584821
foo	one	-0.592235	-0.361735	1.336444	-1.280014
	two	-1.016622	1.409086	0.114743	0.408211
qux	one	0.662941	-1.258482	-0.373214	-0.974658
	two	-0.931004	0.596507	0.148323	0.475039

lect02_eg01.ipynb

目录

- 基本数据对象及操作
- 数据清洗
- 数据合并及分组
- 数据可视化Seaborn
- 实战案例2：客户消费数据分析

数据清洗

数据清洗

- 是数据分析关键的一步，直接影响之后的处理工作
- 数据需要修改吗？有什么需要修改的吗？数据应该怎么调整才能适用于接下来的分析和挖掘？
- 是一个迭代的过程，实际项目中可能需要不止一次地执行这些清洗操作

数据清洗

处理缺失数据

- 判断数据缺失，ser_obj.isnull(), df_obj.isnull()，相反操作为notnull()
- 处理缺失数据
  - df.fillna()，df.dropna()
  - df.ffill()，按之前的数据填充
  - df.bfill()，按之后的数据填充
  - 项目中使用ffill或bfill时，注意数据的排列顺序

lect02_eg02.ipynb

数据清洗

数据变形

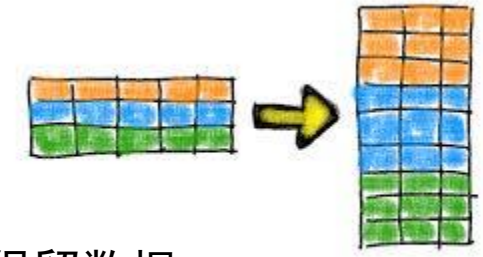

- 处理重复数据
  - 判断数据是否重复，duplicated()
  - 去除重复数据，drop_duplicates()，可指定列及如何保留数据
- 使用函数或map转化数据，通常根据字典进行数据转化
- 替换值，replace()
- 离散化和分箱操作，pd.cut()，返回Categorical对象
- 哑变量操作，pd.get_dummies()
- 向量化字符串操作
  - 字符串列元素中是否包含子字符串，ser_obj.str.contains()
  - 字符串列切片操作，ser_obj.str[a:b]
  - …

lect02_eg02.ipynb

数据清洗

- 向量化字符串操作（续）

Method	Description
`cat`	Concatenate strings element-wise with optional delimiter
`contains`	Return boolean array if each string contains pattern/regex
`count`	Count occurrences of pattern
`extract`	Use a regular expression with groups to extract one or more strings from a Series of strings; the result will be a DataFrame with one column per group
`endswith`	Equivalent to `x.endswith(pattern)` for each element
`startswith`	Equivalent to `x.startswith(pattern)` for each element
`findall`	Compute list of all occurrences of pattern/regex for each string
`get`	Index into each element (retrieve *i*-th element)
`isalnum`	Equivalent to built-in `str.alnum`
`isalpha`	Equivalent to built-in `str.isalpha`
`isdecimal`	Equivalent to built-in `str.isdecimal`
`isdigit`	Equivalent to built-in `str.isdigit`
`islower`	Equivalent to built-in `str.islower`
`isnumeric`	Equivalent to built-in `str.isnumeric`
`isupper`	Equivalent to built-in `str.isupper`
`join`	Join strings in each element of the Series with passed separator
`len`	Compute length of each string
`lower, upper`	Convert cases; equivalent to `x.lower()` or `x.upper()` for each element

目录

数据合并及分组

数据合并

- 维恩图或文氏图（Venn diagram）

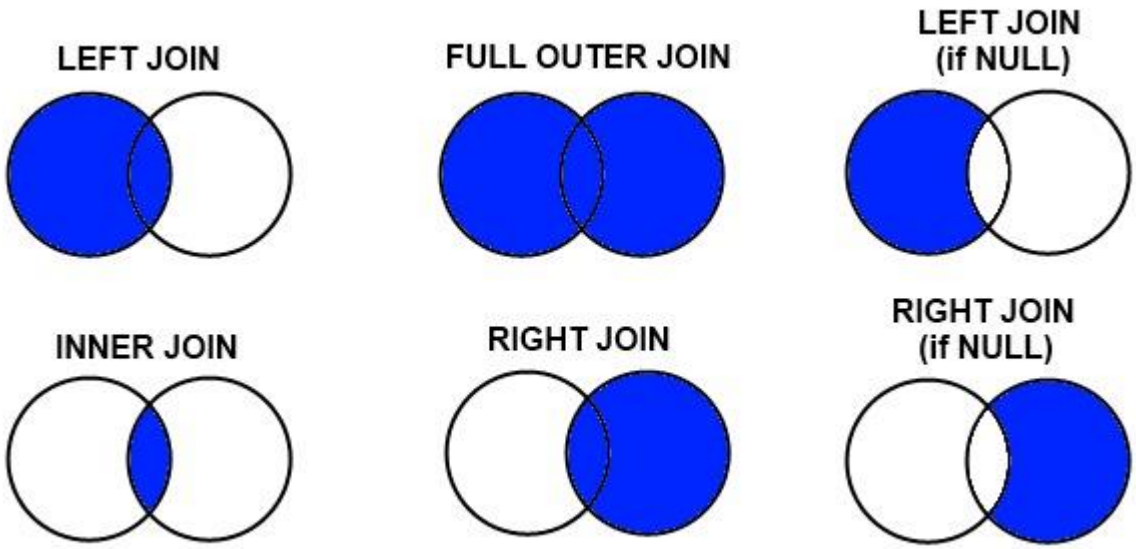

lect02_eg03.ipynb

数据合并及分组

pd.merge

- 根据单个或多个键将不同DataFrame的行连接起来
- 默认将重叠列的列名作为“外键”进行连接
  - on显示指定“外键”
  - left_on，左侧数据的“外键”
  - right_on，右侧数据的“外键”
- 默认是“内连接”(inner)，即结果中的键是交集

```
lect02_eg03.ipynb
```

数据合并及分组

pd.merge (续)

- how指定连接方式
- “外连接”(outer)，结果中的键是并集
- “左连接”(left)
- “右连接”(right)
- 处理重复列名
  - suffixes，默认为_x, _y
- 按索引连接
  - left_index=True或right_index=True

```
lect02_eg03.ipynb
```

数据合并及分组

函数应用

- 可直接使用NumPy的ufunc函数，如abs等
- 通过apply将函数应用到行或列上
  - 注意指定轴的方向，默认axis=0
- 通过applymap将函数应用到每个数据上
- apply的使用场景比applymap要多

```
lect02_eg03.ipynb
```

数据合并及分组

分组 (groupby)

- 对数据集进行分组，然后对每组进行统计分析
- pandas能利用groupby进行更加复杂的分组运算
- 分组运算过程
  - split->apply->combine
  - 拆分：进行分组的根据
  - 应用：每个分组运行的计算规则
  - 合并：把每个分组的计算结果合并起来

lect02_eg03.ipynb

数据合并及分组

分组 (续)

- 分组运算过程
  - split->apply->combine

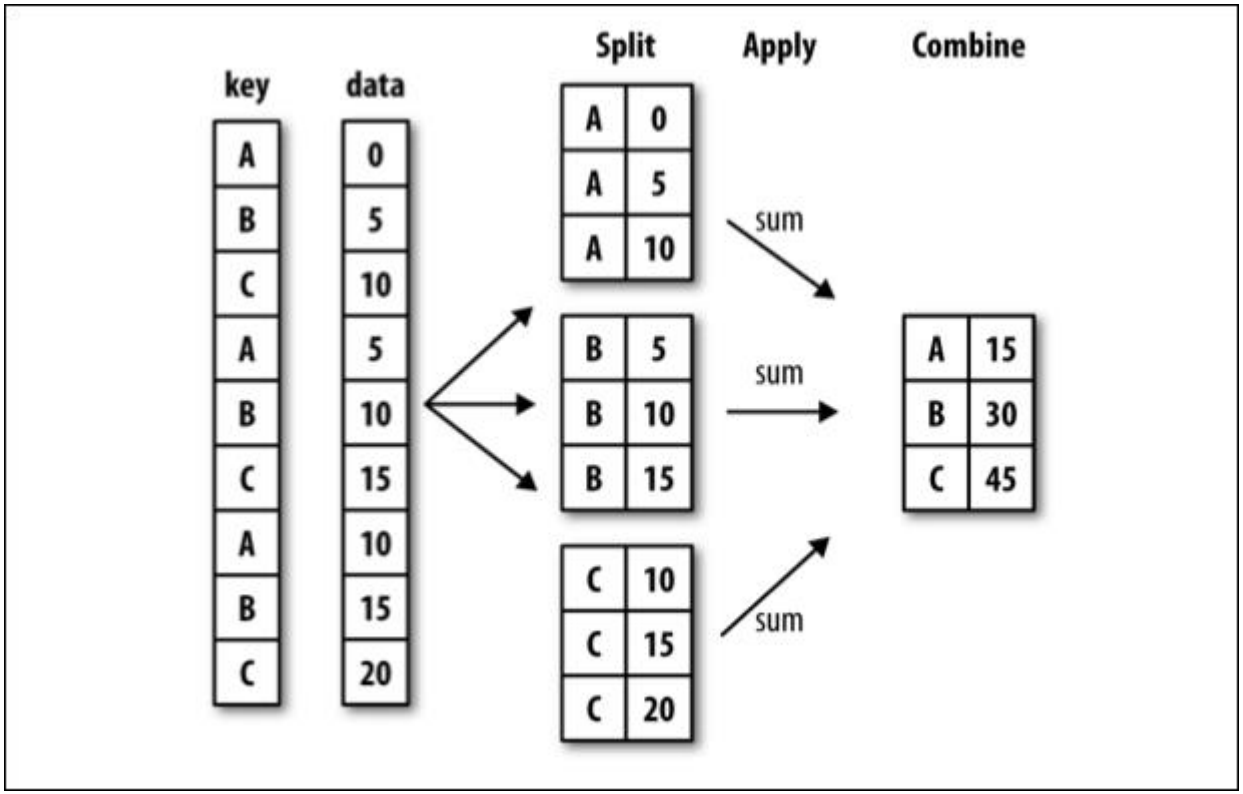

数据合并及分组

分组 (续)

- GroupBy对象：DataFrameGroupBy，SeriesGroupBy
- GroupBy对象没有进行实际运算，只是包含分组的中间数据
- 对GroupBy对象进行分组运算/多重分组运算，如mean()
  - 非数值数据不进行分组运算
- size() 返回每个分组的元素个数
- 按列名分组，obj.groupby(‘label’)
- 按列名多层分组，obj.groupby([‘label1’, ‘label2’])->多层dataframe
- 按自定义的函数分组
  - 如果自定义函数，操作针对的是index
- 实际项目中，通常可以先人为构造出一个分组列，然后再进行groupby

lect02_eg03.ipynb

数据合并及分组

分组 (续)

- GroupBy对象支持迭代操作
  - 每次迭代返回一个元组 (group_name, group_data)
  - 可用于分组数据的具体运算

聚合 (aggregation)

- grouped.agg(func)，数组产生标量的过程，如mean()、count()等
- 常用于对分组后的数据进行计算
- 内置的聚合函数：sum(), mean(), max(), min(), count(), size(), describe()
- 可通过字典为每个列指定不同的操作方法
- 可自定义函数，传入agg方法中

```
lect02_eg03.ipynb
```

目录

Pandas及Seaborn绘图

Pandas 绘图

- df.plot(kind=)
  - kind用于指定绘图的类型
- pd.plotting.scatter_matrix()
- pd.plotting.parallel_coordinates()

lect02_eg04.ipynb

Pandas及Seaborn绘图

什么是Seaborn

- Python中的一个制图工具库，可以制作出吸引人的、信息量大的统计图
- 在Matplotlib上构建，支持numpy和pandas的数据结构可视化，甚至是scipy和statsmodels的统计模型可视化

特点

- 多个内置主题及颜色主题
- 可视化单一变量、二维变量用于比较数据集中各变量的分布情况
- 可视化线性回归模型中的独立变量及不独立变量

Pandas及Seaborn绘图

特点 (续)

- 可视化矩阵数据，通过聚类算法探究矩阵间的结构
- 可视化时间序列数据及不确定性的展示
- 可在分割区域制图，用于复杂的可视化

安装

- conda install seaborn
- pip install seaborn

Pandas及Seaborn绘图

数据集分布可视化

- 单变量分布 sns.distplot()
  - 直方图 sns.distplot(kde=False)
  - 核密度估计 sns.distplot(hist=False) 或 sns.kdeplot()
  - 拟合参数分布 sns.distplot(kde=False, fit=)
- 双变量分布
  - 散布图 sns.jointplot()
  - 二维直方图 Hexbin sns.jointplot(kind='hex')
  - 核密度估计 sns.jointplot(kind='kde')
- 数据集中变量间关系可视化 sns.pairplot()

Pandas及Seaborn绘图

类别数据可视化

- 类别散布图
  - sns.stripplot() 数据点会重叠
  - sns.swarmplot() 数据点避免重叠
  - hue指定子类别
- 类别内数据分布
  - 盒子图 sns.boxplot(), hue指定子类别
  - 小提琴图 sns.violinplot(), hue指定子类别
- 类别内统计图
  - 柱状图 sns.barplot()
  - 点图 sns.pointplot()

目录

实战案例 2

项目名称：客户消费数据分析

- 请参考相应的配套代码及案例讲解文档

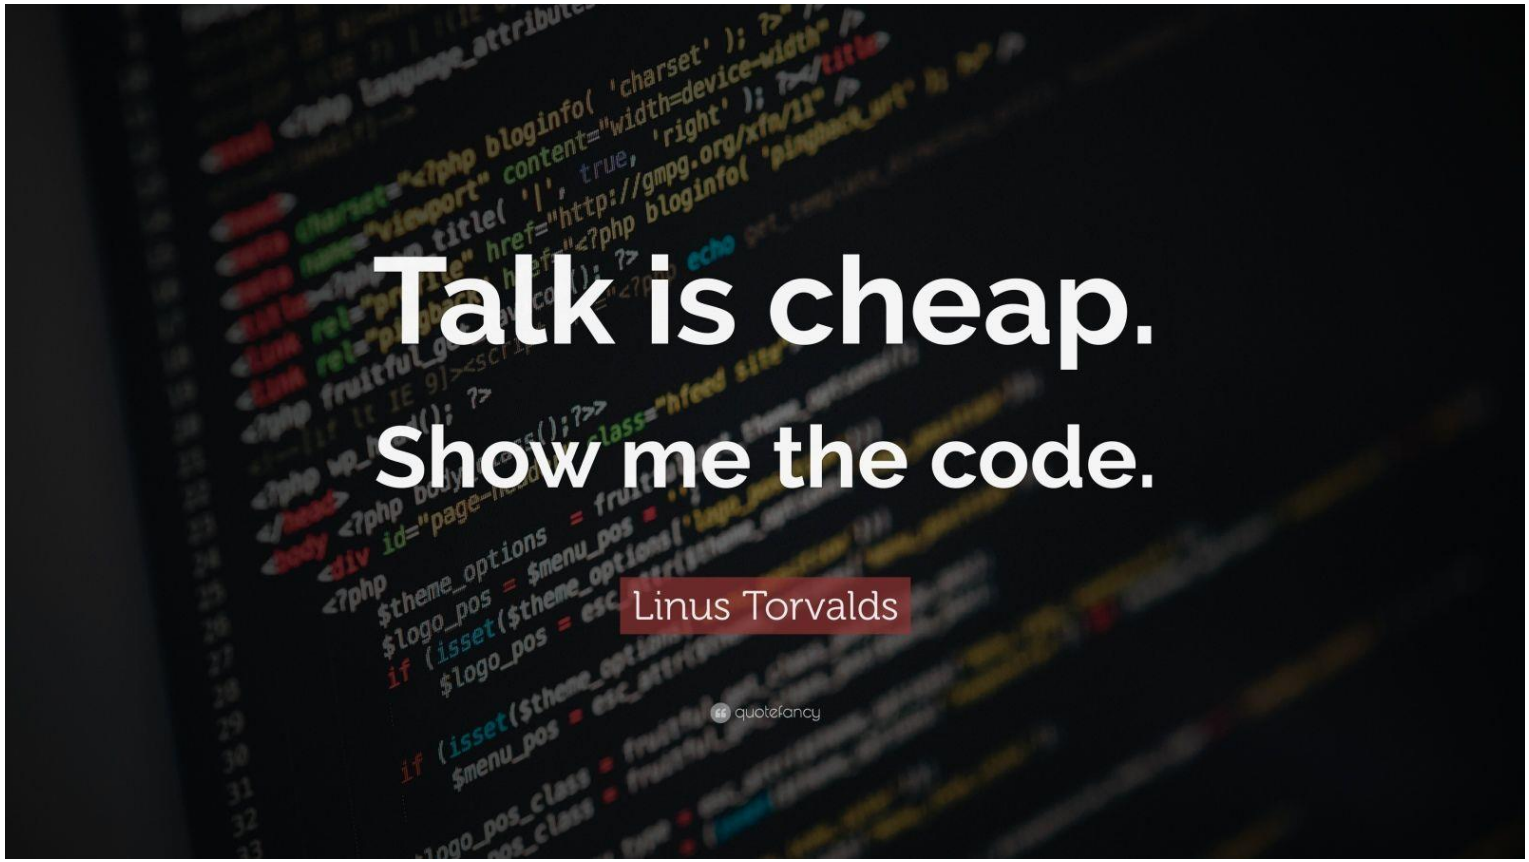

联系我们

小象学院：互联网新技术在线教育领航者

– 微信公众号：**小象学院**